

Severi Haverila

Konenäkösovellukset mineraalirakeiden tunnistuksessa

Sähkötekniikan korkeakoulu

Kandidaatintyö

Espoo 3.12.2012

Vastuupettaja:

TkT Pekka Forsman

Työn ohjaaja:

TkT Olli Haavisto



Aalto-yliopisto
Sähkötekniikan
korkeakoulu

Tekijä: Severi Haverila		
Työn nimi: Konenäkösovellukset mineraalirakeiden tunnistuksessa		
Päivämäärä: 3.12.2012	Kieli: Suomi	Sivumäärä:5+20
Tutkinto-ohjelma: Automaatio- ja systeemitekniikka		
Vastuuopettaja: TkT Pekka Forsman		
Ohjaaja: TkT Olli Haavisto		
<p>Tässä kandidaatintyössä tarkastellaan mineraalirakeiden tunnistuksessa hyödynnettävien konenäkösovellusten toimintaa sekä aiheeseen liittyvän tutkimuksen nykytilaa. Mineraalien tunnistaminen konenäkösovelluksilla muodostuu kolmesta eri vaiheesta: näytteen kuvaaminen, tiedon kerääminen ja tiedon prosessointi.</p> <p>Mineraalirakeiden tunnistamisen näkökulmasta on tärkeää saada tietoa rakeen väristä ja tekstuurista. Valon polarisaatiosuunta sekä pleokroismi vaikuttavat rakeiden väriin. Jotta rakeet voidaan tunnistaa yksilöinä, ne täytyy segmentoida omiksi alueikseen kuvan segmentointimenetelmien avulla.</p> <p>Konenäkösovellukset käyttävät mineraalien tunnistuksessa joko geneettistä ohjelmointia tai keinotekoisia neuroverkkoja. Molemmilla menetelmillä pystytään tunnistamaan mineraalirakeita tarkasti, jopa 100 %:n tarkkuudella. Menetelmien olennaisin ero on se, että yhden keinotekoisien neuroverkon avulla voidaan tunnistaa useiden eri mineraalilajien rakeita. Geneettisellä ohjelmoinnilla voidaan luoda ohjelmia, jotka ovat erikoistuneet vain yhden tietyn mineraalilajin rakeiden tunnistamiseen.</p>		
Avainsanat: mineraalin tunnistaminen, konenäkö, geneettinen ohjelmointi, keinotekoiset neuroverkot, kuvan segmentointi		

Esipuhe

Haluan kiittää Olli Haavistoa hyvästä ohjauksesta, sekä kaikkia niitä henkilöitä, jotka ovat auttaneet minua kandidaatintyöni oikolukemisessa.

Espoo, 6.12.2012

Severi Haverila

Sisältö

Tiivistelmä	ii
Esipuhe	iii
Sisältö	iv
Käsitteet	v
1 Johdanto	1
2 Mineraalien ominaisuudet	2
2.1 Näytteen valokuvaaminen	2
2.2 Väri- ja tekstuuriparametrit	3
3 Kuvan segmentointi	4
3.1 Reunantunnistamismenetelmät	4
3.2 Alueenkasvattamismenetelmät	6
4 Mineraalien tunnistamismenetelmät	7
4.1 Geneettinen ohjelmointi	7
4.2 Keinotekoinen neuroverkko	8
5 Sovellukset	11
5.1 Geneettistä ohjelmointia hyödyntävät sovellukset	11
5.2 Keinotekoisia neuroverkkoja hyödyntävät sovellukset	13
6 Yhteenveto	15
Viitteet	16
Liitteet	18
A Automaattisia alueenkasvattamismenetelmiä	18
B Tarkempaa tutkimustietoa	19

Käsitteet

Yhteisesiintymismatriisi	Yhteisesiintymismatriisi kuvastaa yhdessä esiintyvien arvojen jakaumaa tutkittavassa kuvassa.
Evoluutioalgoritmi	Evoluutioteoriaa jäljittelevä tietokoneohjelman tekotapa.
Serisiittiytyminen	Ilmiö, jossa mineraali vaihtuu hydrotermisestä tai metamorfisesta serisiitiksi eli valkoiseksi kiilteeksi.
Indikatriksi	Geometrinen kuvio, jossa taitekertoimet piirretään valon värähtelysuunnan kanssa yhdensuuntaisina säteinä.

1 Johdanto

Mineraalien tunnistaminen on perinteisesti ollut manuaalista ja aikaavievää työtä, minkä takia on alettu tutkia nopeampia menetelmiä mineraalienrakeiden identifioimiseksi. Manuaalisen tunnistamisen lisäksi mineraaleja on onnistuneesti tunnistettu röntgensäteiden diffraktion sekä konenäkösovellusten avulla. Konenäkö tarkoittaa järjestelmää, jossa tietokonesovellus kerää tietoa kameroilta saaduista kuvista. Tässä kandidaatintyössä tarkastellaan mineraalirakeiden tunnistuksessa hyödynnettävien konenäkösovellusten toimintaa sekä aiheeseen liittyvän tutkimuksen nykytilaa.

Mineraalien tunnistaminen konenäkösovelluksilla muodostuu kolmesta eri vaiheesta: tutkittavan näytteen kuvaaminen, tiedon kerääminen ja sen prosessointi. Tietoa prosessoidaan joko keinotekoisien neuroverkkojen tai geneettisen ohjelmoinnin avulla.

Mineraalien tunnistaminen konenäkösovelluksilla ei ole ongelmaton. Haasteita on varsinkin kuvan segmentoinnissa. Esimerkiksi vierekkäisten samasta mineraalista koostuvien rakeiden erottaminen toisistaan on vaikeaa. Myös mineraalinäytteen valokuvaaminen asettaa omat haasteensa, sillä esimerkiksi valon polarisoitumissuunta vaikuttaa näytteestä saatuun informaatioon. [1]

Konenäkösovelluksilla voidaan mineraalien tunnistamisessa saavuttaa luotettavuudeltaan erinomaisia tuloksia. Tunnistamisprosessin kesto konenäkösovelluksilla on kuitenkin huomattavasti pienempi kuin manuaalisessa tunnistamisessa. Esimerkiksi Holden ym. [2] onnistuivat tutkimaan konenäkösovelluksen avulla mineraalinäytteen yhdessä minuutissa, kun taas saman näytteen manuaaliseen tutkimiseen vaadittu aika oli jopa kuusi tuntia.

Tämän työn toisessa luvussa perehdytään mineraalien ominaisuuksiin, jotka ovat oleellisia mineraalirakeiden identifioimisessa. Kolmas luku käsittelee erilaisia kuvan segmentointimenetelmiä, joiden avulla mineraalirakeet pystytään erottelemaan toisistaan. Neljännessä luvussa kerrotaan erilaisista mineraalin tunnistamismenetelmistä. Viidennessä luvussa perehdytään muutamaan kirjallisuudessa esitettyyn konenäkösovellukseen, joiden avulla mineraalirakeita on onnistuneesti tunnistettu.

2 Mineraalien ominaisuudet

Tässä luvussa perehdytään mineraalien ominaisuuksiin, jotka antavat rakeiden tunnistamisen ja segmentoinnin näkökulmasta tärkeää tietoa. Kyseiset ominaisuudet saadaan näytteistä otetuista valokuvista. Ennen kiviläytteen valokuvaamista niitä täytyy käsitellä, jotta mineraalirakeet pystytään havaitsemaan helpommin. Käsitelykeinoja ovat näytteen kiillottaminen sekä sen hieksi tekeminen. Hie on 30 μm paksu kivistä otettu siivu, joka on asetettu kahden polarisoivan suodattimen väliin. Luvussa 2.1 perehdytään näytteen valokuvausprosessiin, ja luvussa 2.2 mineraalirakeiden väri- ja tekstuuriparametreihin.

2.1 Näytteen valokuvaaminen

Näytteen valokuvaaminen tarkoittaa mineraalirakeiden tunnistamisen näkökulmasta olennaisen tiedon taltioimista. Näytteen valokuvaaminen ei ole yksinkertaista kahdesta syystä:

1. Ristikkäin polarisoituneessa valossa mineraalirakeen väriin vaikuttavat tutkitavan mineraalin ominaisuudet, hieen paksuus sekä indikatriksin suunnan suhde polarisaattoreihin. Lisäksi monet mineraalit näyttävät värittömiltä lineaarisesti polarisoituneessa valossa.
2. Valon polarisaatiosuunnan suhde katselukulmaan saattaa vaikuttaa mineraalin väriin. Tämä pleokroismina tunnettu ilmiö on tärkeässä asemassa tunnistettaessa muuten erittäin samankaltaisia mineraaleja. Kuvassa 1 esitetään havainnollistava esimerkki mineraalissa tapahtuvasta pleokroismista. [1]



Kuva 1: Esimerkki painiitissa esiintyvistä pleokroismista. Lähde: <http://minerals.gps.caltech.edu/FILES/Visible/painite/painite-15-pleochroism.jpg>

Fueter [3] on kehittänyt pyörivän polarisaattorilavan korvaamaan tavallisen petrograafisen mikroskoopin polarisaattorit ja analysaattorin. Tässä järjestelmässä polarisaattorit kääntyvät asteittain askelmootoreiden avulla, minkä seurauksena kuvattavaa hiettä ei tarvitse kääntää. Järjestelmän ansiosta kuvissa esiintyvät pikselit

esittävät aina täysin samaa näytteen pistettä, ja siten järjestelmä vähentää huomattavasti tietokoneella tehtävän laskennan tarvetta. Tavallisessa näytteen valokuvaprosessissa polarisaattorit kääntyvät 0° - 180° siten, että näyte kuvataan aina $0,9^\circ$ välein. Prosessin muodostama kahdensadan kuvan kombinaatio otetaan sekä lineaarisesti että ristikkäin polarisoituneessa valossa.

2.2 Väri- ja tekstuuriparametrit

Mineraalien tunnistaminen perustuu rakeiden väriä ja tekstuuria kuvastavan tiedon käsittelemiseen. Yleensä valokuvat otetaan hyödyntämällä RGB-komponentteja. Näin saatava informaatio on kuitenkin erittäin herkkä valonlähteen vaihtelulle. Siksi väri-informaatio pyritään erottamaan intensiteetistä muuntamalla RGB-värimalli HSI-malliin, joka muodostuu värisävystä, kylläisyydestä ja intensiteettiavaruudesta. Värisävy on määritelty valon aallonpituuden mukaan, eivätkä varjot juurikaan vaikuta sen arvoon [4]. Kylläisyys kuvastaa puhtaan värin määrää, ja sen avulla voidaan esimerkiksi erottaa vaaleansininen sinisestä. [5]

Tekstuurista saatavia parametreja ovat kontrasti, entropia, energia ja homogeenisyys. Nämä neljä parametria kuuluvat niin sanottuihin Haralicksin parametreihin, ja ne saadaan laskettua HSI-mallin intensiteettikomponentin arvoja hyödyntämällä. Kaksiulotteista histogrammia esittävä yhteisesiintymismatriisi (engl. co-occurrence matrix) määrittää $P[i, j]$ arvon, joka vastaa siirtymävektorin (engl. displacement vector) erottamien i ja j arvoista koostuvien pikseleiden lukumäärää. Siirtymävektori kuvataan 2×2 identiteettimatriisina. [5]

Kontrasti kuvastaa tekstuurin hienoutta, ja se lasketaan kuvassa esiintyvän intensiteetin paikallisen vaihtelun avulla seuraavan kaavan mukaisesti:

$$\text{kontrasti} = \sum \sum (i - j)^2 P[i, j]. \quad (1)$$

Tekstuurin entropiaparametri esittää kuvan satunnaisuutta. Parametri saa pieniä arvoja kun yhteisesiintymismatriisi $P[i, j]$ on epäsäännöllinen kaavan

$$\text{entropia} = - \sum \sum P[i, j] \log(P[i, j]) \quad (2)$$

mukaisesti. Energiaparametri esittää kuvassa esiintyvän intensiteetin määrää, ja se esitetään matemaattisesti laskemalla $P[i, j]$:n neliö seuraavan kaavan avulla:

$$\text{energia} = \sum \sum P^2[i, j]. \quad (3)$$

Homogeenisyys kuvastaa jakautuneiden $P[i, j]$:n elementtien läheisyyttä $P[i, j]$:n diagonaaliin kaavassa

$$\text{homogeenisyys} = \sum \sum \frac{P[i, j]}{1 + |i - j|} \quad (4)$$

esitetyllä tavalla. [6]

3 Kuvan segmentointi

Kuvan segmentointi tarkoittaa prosessia, jonka avulla kuvan pikselit jaetaan erilaisiin ryhmiin niiden visuaalisten ominaisuuksien perusteella. Segmentointia hyödynnetään pääosin erilaisten objektien erottamiseen taustasta. Kuvan segmentointimenetelmät ovat tärkeässä asemassa mineraalirakeita tunnistettaessa, sillä useista eri mineraaleista muodostuvien näytteiden rakeet täytyy pystyä tunnistamaan yksilöinä [7].


Kuvan segmentointitekniikoista kertovassa kirjallisuudessa ei ole olemassa yksiselitteistä tapaa jakaa menetelmiä eri kategorioihin. Tässä luvussa perehdytään tarkemmin reunan tunnistamiseen (luku 3.1) sekä alueen kasvattamiseen perustuviin menetelmiin (luku 3.2), koska ne ovat tärkeässä asemassa useassa mineraalin tunnistussovelluksessa. Jälkimmäisen menetelmän kohdalla pääpaino on siemennetyissä alueenkasvattamismenetelmissä (engl. Seeded Region Growing). Muita kuvan segmentointitekniikoita ovat esimerkiksi osittaisdifferentiaaliyhtälöihin perustuvat menetelmät, klusterointi- ja kynnystämistekniikat.

3.1 Reunantunnistamismenetelmät

Reunantunnistamismenetelmien (engl. Edge Detection Methods) avulla kuvista voidaan tunnistaa reunoja eli alueita, joissa tutkitun kuvan visuaaliset ominaisuudet muuttuvat jyrkästi. Kyseisiä alueita etsitään reunaoperaattorien avulla. Näitä operaattoreita hyödyntävät menetelmät eivät ole tehokkaita kohinaa sisältävissä kuvissa. Jos reunaoperaattorin maskia kasvatetaan, se voi vaikuttaa negatiivisesti reunojen paikallistamistarkkuuteen ja samalla myös kasvattaa sovelluksen vaatimaa laskentaa. [8]

Reuna- eli eroavaisuusoperaattorit pyrkivät löytämään kuvasta värin intensiteetin äkillisiä muutoksia [9]. Kaltevuusoperaattorit (kuten esimerkiksi Prewittin, Sobelin ja Laplace-operaattorit) ovat eräs reunaoperaattorien alaluokka. Reunojen lisäksi nämä operaattorit reagoivat myös eristyneisiin pisteisiin, mikä saattaa aiheuttaa virheitä reunan tunnistuksessa. [10]

Prewitt ja Sobel ovat ensimmäisen kertaluvun operaattoreita, kun taas Laplace on toisen kertaluvun operaattori. Toisen kertaluvun operaattorit ovat herkempiä kohinalle kuin ensimmäisen kertaluvun operaattorit. Esimerkiksi Laplace-operaattori tuottaa suurempia Laplace-arvoja kuvassa esiintyvälle kohinalle kuin reunoille. Operaattorissa tunnistusvarmuuteen eivät kuitenkaan vaikuta tutkittavan reunan suunta, toisin kuin esimerkiksi huonosti vinoihin rajoihin reagoivassa Prewittin operaattorissa. Myös Sobelin operaattori suoriutuu edellä mainitusta tehtävästä Prewittin operaattoria paremmin, sillä se painottaa reunantunnistuksessa tarkasteltavan operaattorin läheisyydessä sijaitsevia pikseleitä. Kuvassa 2 esitetään esimerkki Sobelin operaattorin toiminnasta. [10]



Kuva 2: Vasemmalla on mikrovalokuva duniitista. Oikealla on Sobelin reunantunnistusmenetelmällä segmentoitu versio vasemmanpuoleisesta kuvasta [9].

John F. Cannyin kehittämä reunantunnistusmenetelmä on käytössä useissa konenäön sovelluksissa. Canny-operaattorin toiminta koostuu neljästä eri vaiheesta: kuvan ta-soittaminen Gaussin alipäästösuotimen avulla, kaltevuuden suuruuden ja suunnan laskeminen, maksimiarvoja pienempien arvojen suodattaminen ja kaksoiskynnystäminen (engl. double thresholding). [11]

Reunantunnistustekniikat paikantavat objektin reunat tarkemmin kuin alueenkasvattamistekniikat. Lisäksi niillä on myös yksinkertaisempi hallintarakenne. Toisaalta reunantunnistusmenetelmät eivät takaa yhtenäisiä rajoja, mikä saattaa aiheuttaa virheitä alueiden rajaamisessa. Katkonaisten rajojen takia kaksi vierekkäistä mineraaliraetta saatetaan reunoja yhdistettäessä tulkita yhdeksi. Virheiden havaitsemista sekä reunojen yhdistämistä varten on olemassa erilaisia tekniikoita, joita ovat muun muassa heuristinen etsintä, paikallinen käyrän sovitusmenetelmä (engl. local curve fitting), Houghin muunnos ja morfologinen muunnos. [1] Kun näitä menetelmiä hyödyntämällä on saatu aikaiseksi yhtenäiset rajat, niiden sisältö voidaan muuntaa alueeksi raja-täyttöä hyödyntämällä [12].

Heuristinen etsintä perustuu laatufunktion laskemiseen jokaisten katkonaisten rajojen välille siten, että ne rajat yhdistetään, joiden välillä vallitsee paras laatufunktio. Heuristinen etsintä toimii parhaiten kuvissa, joissa laatufunktio on yksinkertainen, yhdistettäviä rajoja on vähän ja niiden välinen etäisyys on lyhyt. [9]

Houghin muunnoksessa yhdistämiskriteerinä toimii yhdistettävien reunojen ja ennalta määritetyn parametrin käyrän sijaintien suhde. Yhdistettävien reunojen tulee sijaita samalla parametrisella käyrällä, jota voidaan muokata parametrien arvoja vaihtamalla. [13]

Morfologisessa muunnoksessa rajat yhdistetään segmentoitavien objektien muodon perusteella. Koska morfologinen muunnos ei tarvitse toimiakseen rajapikseleiden sijaintien lisäksi muuta dataa, se on helppo toteuttaa. Muunnoksen tuottamat rajat voivat kuitenkin olla kiertyneitä. [9] Yleisimpiä morfologisia muunnoksia ovat eroosio, laajeneminen, avaaminen ja sulkeminen [14].

3.2 Alueenkasvattamismenetelmät

Alueen kasvattamiseen perustuvien tekniikoiden idea on segmentoida kuva samankaltaisista pikseleistä muodostuviin alueisiin. Alueenkasvattamismenetelmien avulla muodostetut rajat ovat aina jatkuvia, mutta eivät kuitenkaan yhtä tarkkoja kuin reunantunnistusmenetelmillä saadut. [1] Visuaalisten parametrien lisäksi menetelmät pystyvät hyödyntämään tietoa objektien koosta, muodosta ja intensiteettijakaumasta. Siten voidaan välttää esimerkiksi yksittäisten pisteiden rajaamista omaksi alueeksi. [13]

Siemennetyt alueenkasvattamismenetelmät vaativat aloitusparametreiksi siemenarvoja, jotka koostuvat joko yksittäisistä pikseleistä tai pikselijoukoista. Siemenarvot voidaan valita joko manuaalisesti tai automaattisesti. Niiden oikeanlainen valitseminen on menetelmän toiminnan näkökulmasta tärkeää, sillä huonosti valitut siemenarvot aiheuttavat virheitä kuvan segmentoinnissa. [15]

Siemenarvojen määrittelemien alueiden kasvattaminen voi tapahtua joko yksi kerrallaan tai kaikille alueille samanaikaisesti, jolloin voidaan välttää alueiden ketjuuntuminen. Pikseli yhdistetään alueeseen, jos sen ominaisuudet ovat tarpeeksi samankaltaiset alueeseen kuuluvan naapuripikselin sekä siemenpikselin kanssa. Muuten kyseinen pikseli muodostaa oman alueensa. Alueiden kasvattamisen jälkeen niille lasketaan keskikohdat, joiden perusteella uudet siemenpikselit muodostuvat. [9]

Jokaista aluetta kuvataan omalla symbolilla. Kuvan pikselit voidaan jakaa varattuihin ja vapaisiin. Alueiden kasvattamista jatketaan niin kauan kunnes kaikki kuvan pikselit ovat varattuja, eli kuuluvat johonkin alueeseen. [15] Jos kahden vierekkäisen alueen välinen raja on heikko ja niiden siemenpikselit ovat samankaltaiset, kyseiset alueet voidaan yhdistää. Jos alueille on määritetty minimikoko, sitä pienemmät alueet poistetaan. [9]

Fan ym. [16] ovat kehittäneet automaattisen siemenarvon valitsemismenetelmän. Menetelmässä käytetään ensiksi väriin perustuvaa reunantunnistustekniikkaa, jonka avulla saadaan värikuvasta yksinkertaistettu geometrinen rakenne. Sitten kuvasta havaittujen vierekkäisten rajojen välinen keskipiste valitaan siemenarvoksi. Automaattisesti siemennettyjen menetelmien erilaisia toteutustapoja esitetään liitteessä A (kuva A1). Menetelmien toteutuksiin ei tässä tutkielmassa perehdytä tarkemmin. [15]

4 Mineraalien tunnistamismenetelmät

Mineraalien tunnistamismenetelmien avulla voidaan identifioida tutkittavasta näytteestä segmentoidut mineraalirakeet. Tässä luvussa perehdytään geneettiseen ohjelmointiin (luku 4.1) sekä keinotekoiisiin neuroverkkoihin (luku 4.2), joiden toimintaan mineraalien tunnistamisessa hyödynnettävät konenäkösovellukset perustuvat. Geneettisestä ohjelmoinnista kertova luku perustuu lähteisiin [7] ja [17], ja neuroverkoista kertova luku perustuu lähteeseen [18].

4.1 Geneettinen ohjelmointi

Geneettinen ohjelmointi (GO) on evoluutioalgoritmi, jossa populaation yksilöt ovat tietokoneohjelmia. Sen avulla ohjelmajoukkoja kehitetään iteratiivisesti uusiksi geneettisiä operaattoreita hyödyntäen. GO:n ideana on saada tietokoneet ratkaisemaan ongelmia ilman yksiselitteisiä ohjeita, ja sen toiminta koostuu viidestä eri vaiheesta:

1. Valitaan satunnainen alkujoukko erilaisia ohjelmia.
2. Testataan, kuinka hyvin kukin ohjelmista sopii halutun ongelman ratkaisemiseen. Testaamisessa käytetään hyvyysfunktioita, joka antaa jokaiselle joukon yksilölle numeerisen arvion siitä, kuinka hyvin ne pystyvät ratkaisemaan halutun ongelman.
3. Joukosta valitaan ohjelmia geneettisiä operaatioita varten suhteessa saatuihin hyvyysarvoihin. Geneettisten operaatioiden avulla luodaan uusia ohjelmia. Tärkeimmät geneettiset operaatiot ovat risteytys ja mutaatio. Risteytyksessä luodaan uusia ohjelmia yhdistämällä satunnaisesti valittuja paloja kahdesta eri ohjelmasta. Mutaatiossa luodaan uusia ohjelmia muokkaamalla satunnaisella tavalla satunnaisesti valittua osaa tietyistä ohjelmista. Muita GO:ssa käytettäviä geneettisiä operaatioita ovat esimerkiksi kopiointioperaatiot sekä arkkitehtuurin muokkaamisoperaatiot.
4. Palataan kohtaan kaksi, ja toistetaan näitä askeleita generoiduille jälkeläisohjelmille kunnes jokin pysäyttävä kriteeri täyttyy.
5. Palautetaan parhaiten kriteerit täyttävä ohjelma.

GO vaatii toimiakseen tietyt alustavat toimenpiteet, joita ovat terminaali- ja funktiojoukon valitseminen sekä hyvyysfunktion, kontrolliparametrien ja lopetusehdon määrittäminen.

Terminaalijoukko muodostuu ohjelman ulkoisista sisääntuloista, parametrittomista funktioista ja vakioista. Esimerkiksi mineraalirakeiden tunnistamisessa käytettävissä sovelluksissa terminaalijoukkoon kuuluvat tekstuuri- ja väriparametrit. Funktiojoukon koostumukseen vaikuttaa ratkaistava ongelma. Esimerkiksi yksinkertaisessa

matemaattisessa ongelmassa funktiojoukko koostuu erilaisista aritmeettisista operaatioista. Terminaali- ja funktiojoukko muodostavat GO:n primitiivisen joukon, ja täten myös epäsuorasti määrittelevät käytettävän hakuvaruuden.

Hyvyysfunktio arvioi generoituja ohjelmia numeerisesti. Esimerkiksi mineraalirakeiden tunnistamissovelluksissa se voi verrata ohjelman näytteestä tunnistamia rakeita mallituloksiin, jotka on saatu tunnistamalla mineraalirakeet manuaalisesti.

Kontrolliparametrit ohjaavat GO:n suorittamista. Niitä ovat muun muassa alkiojoukon koon määrittäminen, geneettisten operaatioiden suoritustodennäköisyydet, ohjelmien maksimilukumäärä sekä muut GO:n ajoon liittyvät kriteerit. Tärkein näistä parametreista on alkiojoukon koon määrittäminen.

Lopetusehto määrittelee sen, kuinka hyvin kelpuutettavan ohjelman tulee suoriutua vaaditusta tehtävästä. Lopetusehtoon voi myös liittyä kriteeri sukupolvien maksimilukumäärälle.

4.2 Keinotekoinen neuroverkko

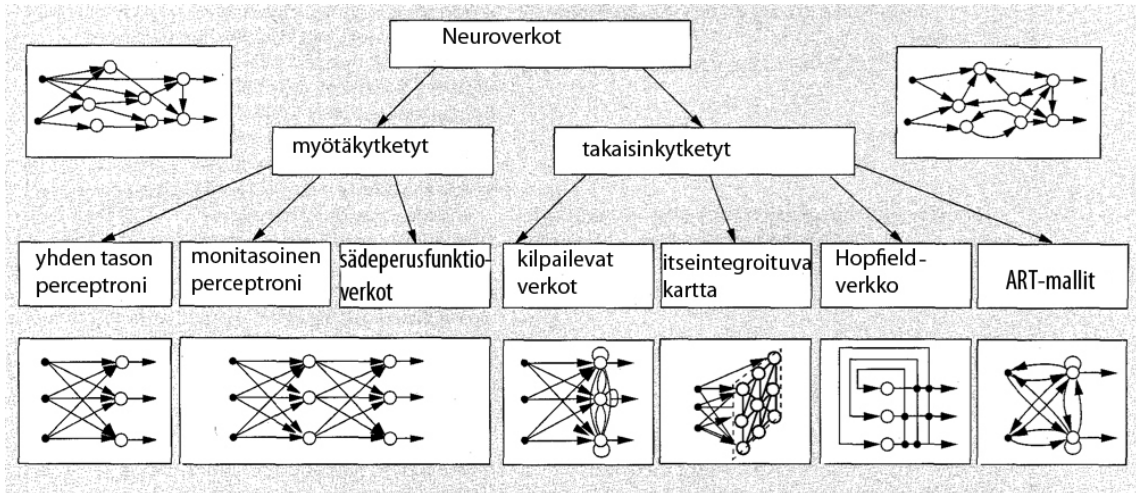
Keinotekoinen neuroverkko (KNV) on matemaattinen malli, joka on kehitetty biologisten neuroverkkojen pohjalta simuloimaan oppimista. KNV:t ovat suuria rinnakkain suoriutuvia järjestelmiä. Ne koostuvat valtavasta määrästä toisiinsa kytkettyjä yksinkertaisia prosessoreja, joita kutsutaan neuroneiksi. KNV:a voidaan kuvitella painotettuna suunnattuna verkkona, jossa neuronit ovat solmuja ja suunnatut reumat ovat yhteyksiä neuronien sisään- ja ulostulon välillä.

Tietokoneet ovat hyviä nopeita aritmeettisiä ohjelmia varten. Perinteisesti ihmiset ovat kuitenkin pystyneet ratkomaan tietokoneita paremmin ongelmia, joissa vaaditaan seuraavia ominaisuuksia:

- virhetoleranssi
- häiriöitä sisältävän datan käsittely
- suuri rinnakkaisuus
- sopeutumiskyky. [19]

Tämänkaltaisissa ongelmissa KNV:t näyttävät vahvuutensa. Ne ovat erityisen hyödyllisiä vaativien havainto-ongelmien ratkaisemisessa. Harjoitusdatan kattavuus ja laadukkuus ovat erittäin kriittisiä KNV:n toiminnan näkökulmasta.

KNV:t voidaan jakaa neuronien yhteyksissä esiintyvien silmukoiden perusteella kahteen eri luokkaan: myötäkytkettyihin eli silmukattomiin verkkoihin ja takaisinkytkettyihin eli silmukallisiin verkkoihin. Myötäkytketyt verkot ovat staattisia, eli niiden ulostulo tietylle sisääntulolle pysyy samana riippumatta verkon tilasta. Takaisinkytketyt verkot ovat dynaamisia, eli niissä verkon ulostulo tietylle sisääntulolle muuttuu verkon tilan mukaisesti. Erilaisia neuroverkkoarkkitehtuureja esitetään kuvassa [3](#).



Kuva 3: Myötä- ja takaisinkytkettyjen verkkojen arkkitehtuureja. Muokattu Anil ym. tekemän kuvan pohjalta [18].

KNV:n toimimisen lähtökohta on niiden kyky jäljitellä oppimista. Oppimisprosessi perustuu verkkojen arkkitehtuuriin ja neuronien välisten yhteyksien painoarvojen muokkaamiseen. KNV:ja opetetaan hyödyntämällä niiden kykyä oppia esimerkkien avulla. KNV:t osaavat annettujen esimerkkien eli harjoitusdatan avulla määrittellä sisään- ja ulostulojen välillä vallitsevia yhteyksiä.

Oppimisprosessi voidaan luokitella kolmeen eri kategoriaan: valvottu, valvoton ja hybridioppiminen. Valvotussa oppimisessa verkolle annetaan mallivastaukset kaikille sisääntuloille, minkä perusteella verkko pyrkii päivittämään sisältämänsä yhteydet sellaisiksi, että niiden avulla voidaan tuottaa mahdollisimman hyvin mallivastauksia vastaavat ulostulot. Valvomattomassa oppimisessä verkko pyrkii sisääntuloja tutkimalla muokkaamaan mallinsa oikeanlaiseksi. Hybridissä oppimisessä yhdistetään sekä valvottu että valvoton oppiminen.

Neuronit suorittavat erilaisia matemaattisia funktioita ja ovat kytkettynä toisiinsa synapsien avulla. Synapsit sisältävät kytkennän painokertoimen, jonka avulla dataa manipuloidaan. Sisääntulot summataan yhteen ja tämä summa ohjataan aktivaatiofunktion läpi, joka määrittelee neuronin ulostulon. Esimerkiksi yksikköaskel-, sigmoid- ja gaussianfunktioita voidaan hyödyntää aktivaatiofunktiona.

Erilaisia neuronimalleja on olemassa useita. Esimerkiksi McCullohin ja Pittin kehittämässä neuronimallissa hyödynnetään binääristä kynnysyksikköä neuronin ulostulon määrittelemisessä. Matemaattisesti esitettynä saadaan yhtälö

$$y = \theta\left(\sum_{j=1}^n w_j x_j - u\right), \quad (5)$$

jossa θ on yksikköaskelfunktio (eli neuronin aktivaatiofunktio), w_j on j :nnen sisääntulon synapsin paino ja u kynnys. Käytännössä kyseinen neuronin laskee painotetun

summan saamistaan sisääntuloista. Jos kyseinen summa on suurempi kuin määritetty kynnys, neuronin antama ulostulo on yksi. Muissa tapauksissa ulostulo on nolla.

5 Sovellukset

Tässä luvussa esitetään konenäkösovelluksista mineraalirakeiden tunnistuksessa tehtyjen tutkimusten tuloksia. Tutkitut konenäkösovellukset voidaan luokitella kahden eri kategoriaan tunnistuksessa hyödynnettävien menetelmien mukaan: KNV-sovellukset ja GO-sovellukset. Näistä sovelluksista tehtyjen tutkimusten tuloksiin perehdytään luvuissa [5.1](#) ja [5.2](#).

Sekä geneettisellä ohjelmoinnilla että keinotekoisilla neuroverkoilla on onnistuttu tunnistamaan mineraalirakeita tarkasti. Menetelmien olennaisin ero on se, että yhden keinotekoisien neuroverkon avulla voidaan tunnistaa useiden eri mineraalilajien rakeita. Geneettisellä ohjelmoinnilla voidaan luoda ohjelmia, jotka ovat erikoistuneet vain yhden tietyn mineraalilajin rakeiden tunnistamiseen. Ross ym. tutkivat geneettisen ohjelmoinnin avulla tuotetun universaalien mineraalintunnistamissovelluksen toteuttamisen mahdollisuutta, saavuttaen kuitenkin vain 56,4 %:n tunnistamistarkkuuden. [7]

5.1 Geneettistä ohjelmointia hyödyntävät sovellukset

Tässä luvussa perehdytään GO:a hyödyntävien konenäkösovellusten sopivuuteen mineraalirakeiden tunnistuksessa. Ross ym. ovat tutkineet tällaisten sovellusten toimintaa, ja raportoivat tutkimuksestaan artikkelissa "Automatic mineral identification using genetic programming" [7].

Sovelluksessa käytetään luvussa [2](#) esitettyä pyörivää polarisaattorilavaa. Mineraalien tunnistamisessa hyödynnettävä informaatio päätettiin rajata ainoastaan visuaalisiin parametreihin, kuten näytteen väristä ja tekstuurista saatuun informaatioon (luku [2](#)). Tutkimuksessa käytetyt parametrit esitetään liitteessä [B](#) (taulukko [B1](#)).

GO:ssa tarvittava harjoitusdata saadaan geologin näytteistä manuaalisesti tunnistamien mineraalirakeiden avulla. Tunnistettuja näytteitä on yhteensä 44 kappaletta, joiden avulla harjoitusdata luodaan seuraavia mineraaleja varten: kvartsi, kalimaa-sälpä, plagioklaasi, biotiitti, muskoviitti, sarvivälke, klinopyrokseeni, oliviini, granaatti, kalsiitti sekä läpinäkymättömiä mineraaleja. Mineraali on läpinäkymätön, jos se ei hietä tutkittaessa lähetä valoa mikroskooppiin. Tunnistettujen näytteiden sisältämää mineraalijoukkoa kutsutaan mineraalitietokannaksi.

Tutkimuksessa käytettiin kahta erilaista ohjelmointikieltä: sisäkkäistä päätöspuu-kieltä (L1) sekä kompleksisempaa L2-kieltä. L1-kieli muodostuu sisäkkäisistä Jos-niin-lausekkeista, vertailuoperaattorista (<) sekä loogisista vakioista (True ja False). L2-kieli sisältää näiden ominaisuuksien lisäksi myös matemaattisia funktioita parametreille sekä liukulukuaritmetiikkaa. Taulukosta [1](#) löytyvät esimerkit GO:n generoimista ohjelmista molemmilla edellä mainituilla kielillä. Ohjelmat tunnistivat mineraalit 90,1 %:n (L1) ja 98,0 %:n (L2) tarkkuudella.

Tutkimuksessa suoritettiin kaksi erilaista koetta. Ensimmäisessä kokeessa käytettiin

Taulukko 1: Esimerkki geneettisen ohjelmoinnin avulla generoiduista ohjelmista L1- ja L2- kielillä. Parametrit p_1, \dots, p_{35} esitetään liitteessä B (taulukko B1).

```

L1:
if p3 < p2
  then if p3 < p2
    then (p21 < p33)
    else if p26 < p26
      then (p2 < p25)
      else (p21 < p33)
  else if p25 < p2
    then False
    else if p23 < p2
      then (if p4 < p16 then False else False)
      else if p3 < p2
        then (p9 < p21)
        else if p2 < p26
          then if p26 < p26
            then (p19 < p14)
            else if p24 < p6
              then False
              else if p25 < p2
                then False
                else True
          else (p9 < p21)

L2:
if (((((0.71899/p35)-(0.71899/p35)) < (p16*p14+p21))
  and ((p3+p17) < (p16*p14+max(p25,p32)))
  and ((p5+p10) < (max(p26,p7)-(p34-p23)))
  or (not (False or True))))
then (max((min((p10-p26),(p3+p10+min(p2,p26)))
  +(p5+p10)*p6*p6),
  min(p24,p12)) > p8)
  and (min(p2,p26) < min(p9,p8))
else (((p3+p10+min(p2,p26))-(p26*p6*p6))
  < (p33/p7))}

```

pientä harjoitusjoukkoa, joka koostui 34:stä positiivisesta ja 340:stä negatiivisesta esimerkistä yhtä ajoa kohden. Toisessa kokeessa positiivisten esimerkkien lukumäärä kaksinkertaistettiin seitsemäänkymmeneen kappaleeseen. Toista koetta ei pystytty suorittamaan neljälle mineraalille, sillä niiden lukumäärä tunnistettavissa näytteissä oli liian pieni. Näitä mineraaleja olivat biotiitti, muskoviitti, sarvivälke ja klinopyrokseeni.

Ohjelmointikielillä L1 ja L2 saadut tulokset eivät eronneet toisistaan merkittävästi. Huomattava kielten välinen ero oli niiden nopeus: L2-kieltä hyödyntävien GO-ajojen suoritusaika oli jopa kolme kertaa pidempi kuin vastaavan L1-kieltä hyödyntävän ajon. Tämä johtuu L2-kielessä hyödynnettävien liukulukujen aritmetiikan hitaudesta.

Liitteessä B (taulukko B2) esitetään tutkimuksessa saadut tulokset jokaiselle tutkitulle mineraalille. Tulosten perusteella voidaan todeta geneettisen ohjelmoinnin soveltuvan hyvin mineraalien tunnistamiseen. Useampien positiivisten esimerkkien käyttäminen harjoitusjoukossa tuotti yleisellä tasolla parempia tuloksia keskimääräiseen mineraalin tunnistamiskykyyn. Siitä huolimatta monissa L1-kieltä hyödyntävissä ohjelmissa tulokset olivat marginaalisesti päinvastaiset. Kyseisen ilmiön ar-

vellaan johtuneen luontaisesta tilastollisesta virhemarginaalista sekä siitä, että pienempi positiivisten esimerkkien muodostama joukko kuvasti kyseisten mineraalien yleisiä piirteitä paremmin. Lisäksi myös voidaan olettaa, että tutkimuksessa hyödynnetty mineraalitietokanta sisältää virheellisesti tunnistettuja mineraaleja, joiden avulla muodostetut harjoitusjoukot luonnollisesti huonontavat ohjelman suorituskyyä.

Yksi tutkimuksessa havaittu ilmiö oli, että 34:stä positiivisesta esimerkistä muodostuneet harjoitusjoukot aiheuttivat yli-opettamista. Tämä tarkoittaa sitä, että tunnistamiskriteereistä muotoutui liian tarkkoja, jolloin niiden avulla ei pystytäkään tunnistamaan tarkasti harjoitusjoukkoon kuulumattomia mineraalirakeita. Yli-opettamisen seurauksena ohjelmien suorituskyyä kärsii. Kyseistä ilmiötä ei havaittu toisessa kohteessa, jossa positiivisten esimerkkien lukumäärää kasvatettiin.

5.2 Keinotekoisia neuroverkkoja hyödyntävät sovellukset

Tässä luvussa perehdytään kirjallisuudessa esitettyihin KNV:ja hyödyntäviin mineraalintunnistussovelluksiin. Luku pohjautuu lähteissä [5] ja [20] esitettyihin tutkimuksiin. Baykan ym. [20] tutkivat KNV:en kykyä tunnistaa rakeiden väriparametrien avulla näytteistä seuraavia mineraaleja: kvartsi, muskoviitti, biotiitti, kloriitti ja läpinäkymättömiä mineraalirakeita. Thompson ym. [5] tekemässä tutkimuksessa hyödynnetään mineraalirakeiden väriparametrien lisäksi myös niiden tekstuuriparametreja. Tekstuuri- ja väriparametrit on selitetty tarkemmin luvussa 2. Thompson ym. pyrkivät tunnistamaan KNV-sovellusten avulla kvartsi-, kalimaasälpä-, plagioklaasi-, biotiitti-, sarvisälke-, klinopyrokseeni-, oliviini-, granaatti-, kalsiitti- sekä läpinäkymättömiä mineraalirakeita. Mineraalit saatiin molemmissa tutkimuksissa vulkaanisista, metamorfisista ja sedimenttikivilajeista koostuvista näytteistä.

Artikkelissa [5] neuroverkkojen rakentamiseen hyödynnettävät sisääntuloparametrit löytyvät liitteestä B (taulukko B1). Parametrit voidaan luokitella niiden tärkeyden perusteella kolmeen eri luokkaan:

1. parametrit, jotka KNV valitsee aina,
2. parametrit, jotka KNV valitsee joskus
3. ja parametrit, joita KNV ei koskaan valitse.

Parametrien luokitus voidaan osittain selittää geologisilla syillä. Esitetään, että jokin luokkaan 2 kuuluvat parametrit sisältävät keskenään päällekkäistä tietoa, mikä seurauksena molempia parametreja ei tarvita tietyn mineraalin tunnistamiseen. Esimerkiksi parametrit p10 ja p17 (Liite B taulukko B1) tuottavat keskenään päällekkäistä tietoa väritöntä mineraalirakeita tutkittaessa.

Molemmissa tutkimuksissa todettiin, että KNV:n avulla voidaan mineraaleja tunnistaa tarkasti. Thompson ym. onnistuivat tunnistamaan tutkimansa mineraalit 90 % - 98 % tarkkuudella, kun taas Baykan ym. tekemä sovellus saavutti 81 % - 98 % tun-

nistamistarkkuuden. Tarkkuuksien ero johtuu pääosin siitä, että Thompson ym. hyödynsivät rakeista saatavien väriparametrien lisäksi myös tekstuuriparametreja.

Tekstuuriparametrit osoittautuivat erityisen tärkeiksi värittömien mineraalien, kuten kvartsin, plagioklaasin ja kalimaasälvän, erottamisessa toisistaan. Thompson ym. [5] osoittivat tutkimuksessaan, että edellä mainituista mineraaleista kvartsin ja plagioklaasin tunnistamistarkkuus ei kärsi, jos tunnistaminen tapahtuu pelkkien tekstuuriparametrien avulla. Kalimaasälvän tunnistamistarkkuus kuitenkin las-
ki 87 %:sta 82 %:iin, kun väriparametrit jätettiin huomiotta. Perusteluna tälle esitetään, että esimerkiksi rakeen väriparametreista havaittava serisiittiytyminen tuottaa joidenkin mineraalien tunnistamisen näkökulmasta hyödyllistä tietoa.

Tutkimuksissa huomattiin, että eräille mineraaleille, kuten kvartsille, granaatille ja kalsiitille, noin viidestäkymmenestä esimerkkirakeesta koostuvan harjoitusdatan avulla voidaan jo saada optimaalisia tunnistamistarkkuuksia. Tulokseen päädyttiin, koska tutkittaessa KNV:n toimintaa suuremmalla harjoitusdatalla, ei tunnistamistarkkuus kyseisien mineraalien kohdalla enää parantunut. Molemmissa artikkeleissa todettiin, että KNV:en avulla pystytään tunnistamaan kvartsirakeita erityisen tarkasti. Jopa harjoitusdatan muodostuessa vain alle 10 %:sta tunnistettavista kvartsirakeista, KNV:lla saavutetaan yli 95 %:n tunnistamistarkkuus.

Tutkimuksien perusteella voidaan todeta, että KNV:ja hyödyntävät mineraalin tunnistamissovellukset ovat suhteellisen robusteja. Niiden avulla pystytään tunnistamaan mineraaleja eri valo-olosuhteissa kuvatuista näytteistä ilman, että tarkkuus kärsii.

6 Yhteenveto

Konenäkösovelluksilla voidaan näytteistä tunnistaa mineraalirakeita erittäin tarkasti. Lisäksi kyseiset sovellukset suoriutuvat tunnistamistehtävistä huomattavasti nopeammin kuin mihin ihminen kykenee. Mineraalirakeiden tunnistamisprosessi kone-
näkösovellusten avulla voidaan jakaa kolmeen eri vaiheeseen: tutkittavan näytteen valokuvaaminen, tiedon kerääminen ja tiedon prosessointi.

Näytteen valokuvaamisessa täytyy ottaa huomioon, että näytteestä saadaan kerättyä tarpeeksi informaatiota tunnistamista varten. Mineraalirakeiden väriin vaikuttavat tutkimusolosuhteet. Mineraalien tunnistamisen näkökulmasta on olennaista tietää, minkä värisenä rae näkyy lineaarisesti polarisoituneessa ja ristikkäin polarisoituneessa valossa. Lisäksi valon polarisaatiosuunnan suhde katselukulmaan saattaa vaikuttaa mineraalin väriin. Tätä ilmiötä kutsutaan pleokroismiksi. Fuetenin kehittämän pyörivän polarisaattorilavan avulla saadaan kuvasta tarvittava informaatio helposti ilman, että tutkittavaa hietä joudutaan kääntämään.

Mineraalin tunnistamisen näkökulmasta tärkeät visuaaliset ominaisuudet voidaan jakaa väri- ja tekstuuriparametreihin. Väriparametrit muodostuvat värisävystä ja kylläisyydestä, kun taas tekstuuriparametrit koostuvat kontrastista, entropiasta, energiasta sekä homogeenisyydestä. Perinteisessä valokuvauksessa hyödynnetty RGB-komponentit ovat herkkiä olosuhteiden vaihtelulle, minkä seurauksena mineraaleja tunnistettaessa hyödynnetään RGB-värimallin sijaan HSI-mallia, jossa intensiteetti on erotettu väriin liittyvästä informaatiosta.

Mineraalien tunnistamisen näkökulmasta on olennaista erotella rakeet toisistaan, jotta ne voidaan tunnistaa yksilöinä. Erilaisia kuvan segmentointimenetelmiä ovat muun muassa reunan tunnistamiseen sekä alueen kasvattamiseen perustuvat menetelmät. Rakeiden segmentointi kuvasta ei kuitenkaan ole ongelmatonta. Haasteita tuottavat muun muassa tunnistettujen reunojen yhdistäminen sekä siemenarvojen automaattinen valitseminen.

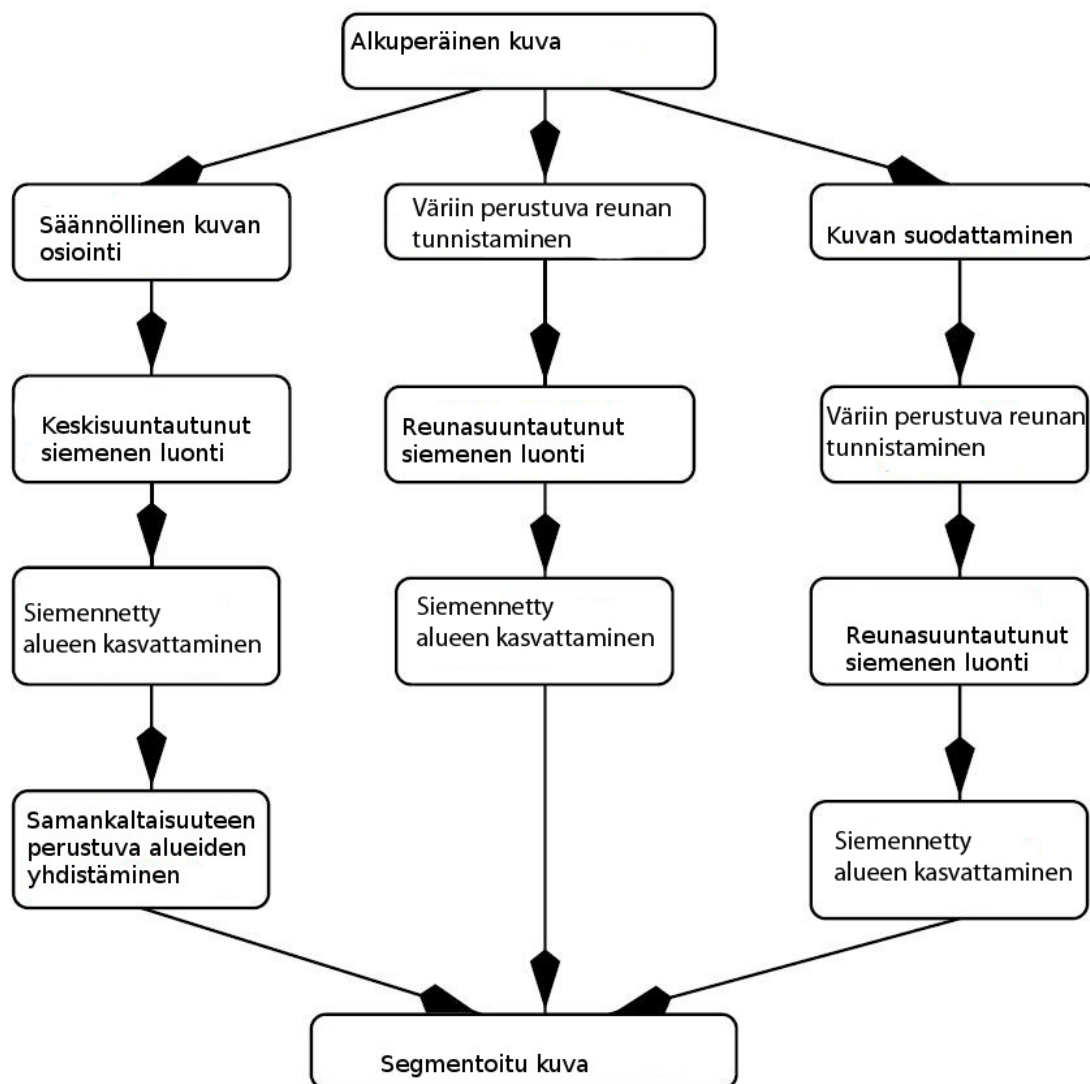
Konenäkösovellukset käyttävät mineraalien tunnistuksessa joko geneettistä ohjelmointia tai keinotekoisia neuroverkkoja. Vaikka geneettisellä ohjelmoinnilla on saavutettu erittäin hyviä tuloksia, suurin potentiaali on keinotekoisissa neuroverkoissa. Syy tähän on niiden kyky tunnistaa useita mineraaleja kerrallaan. Tulevaisuudessa geologien ei todennäköisesti enää tarvitse manuaalisesti tunnistaa mineraalirakeita, vaan ne tunnistetaan esimerkiksi keinotekoisia neuroverkkoja hyödyntävillä kone-
näkösovelluksilla, jotka kykenevät identifioimaan tarkasti ja robustisti yleisimmät mineraalit.

Viitteet

- [1] Bibo Lu and Weixing Wang. Mineral grain boundary detection with image processing method: From edge detection operation to level set technique. Technical report, Henan Teknillinen Yliopisto, Kiina, 2011.
- [2] EJ Holden, S. Moss, JK Russell, and MC Dentith. An image analysis method to determine crystal size distributions of olivine in kimberlite. *Computational Geosciences*, 13(3):255–268, 2009.
- [3] F. Fueten. A computer-controlled rotating polarizer stage for the petrographic microscope. *Computational Geosciences*, 23(2):203–208, 1997.
- [4] T. Carron and P. Lambert. Color edge detector using jointly hue, saturation and intensity. volume 3. IEEE International Conference, 1994.
- [5] S. Thompson, F. Fueten, and D. Bockus. Mineral identification using artificial neural networks and the rotating polarizer stage. *Computational Geosciences*, 27(9):1081–1089, 2001.
- [6] A. Chaddad, C. Tanougast, A. Dandache, and A. Bouridane. Extraction of haralick features from segmented texture multispectral bio-images for detection of colon cancer cells. IEEE International Conference, 2011.
- [7] BJ Ross, F. Fueten, and DY Yashkir. Automatic mineral identification using genetic programming. *Mach Vision Appl*, 13(2):61–69, 2001.
- [8] M.A. Wani and B.G. Batchelor. Edge-region-based segmentation of range images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 16(3):314–319, 1994.
- [9] Y. Zhou, J. Starkey, and L. Mansinha. Segmentation of petrographic images by integrating edge detection and region growing. *Computational Geosciences*, 30(8):817–831, 2004.
- [10] S.K. Pal, N.R. and Pal. A review on image segmentation techniques. *Pattern Recognition*, 26(9):1277–1294, 1993.
- [11] J Canny. A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6):679–698, 1986.
- [12] E.G.M. Petrakis. Image segmentation. Luentokalvo : Computer Vision, 12 2010.
- [13] Laaksonen J. Digital image processing. Digital Image Processing -kurssi, Aalto-yliopisto, 2011.
- [14] S. Laroche and C. Forget. Grain sizing of anodized aluminum by color image analysis. *Materials Characterization*, 36(4):203–211, 1996.

- [15] J. Fan, G. Zeng, M. Body, and M.S. Hacid. Seeded region growing: an extensive and comparative study. *Pattern Recog. Lett.*, 26(8):1139–1156, 2005.
- [16] J. Fan, D.K.Y. Yau, A.K. Elmagarmid, and W.G. Aref. Automatic image segmentation by integrating color-edge extraction and seeded region growing. *IEEE Transactions on Image Processing*, 10(10):1454–1466, 2001.
- [17] R. Poli, W.B. Langdon, N.F. McPhee, and J.R. Koza. Genetic programming: An introductory tutorial and a survey of techniques and applications. Technical Report CES-475, Essexin yliopisto, Iso-Britannia, 2007.
- [18] A.K. Jain, J. Mao, and K.M. Mohiuddin. Artificial neural networks: A tutorial. *IEEE Computer*, 29(3):31–44, 1996.
- [19] RC Chakraborty. Fundamentals of neural networks. AI Kurssin luento 37-38, Kesäkuu 2010.
- [20] N.A. Baykan and N. Ylmaz. Mineral identification using color spaces and artificial neural networks. *Computational Geosciences*, 36(1):91–97, 2010.

A Automaattisia alueenkasvattamismenetelmiä



Kuva A1: Kolmen automaattisen siemennetyn alueenkasvattamismenetelmän pääkohdat. Muokattu Fan ym. tekemän kuvan pohjalta [15].

B Tarkempaa tutkimustietoa

Taulukko B1: Visuaaliset parametrit (R=ristikkäin polarisoitunut valo, L=lineaarisesti polarisoitunut valo). Muokattu Ross ym. tekemän taulukon pohjalta [7].

Maksimi R intensiteetti		
p1	värisävy	
p2	kyllästys	Maksimi R sijainti
p3	intensiteetti	p22 Kontrasti
p4	kontrasti	p23 Entropia
p5	entropia	p24 Energia
p6	energia	p25 Homogeenisyys
p7	homogeenisyys	
		Minimi L sijainti
Maksimi L intensiteetti		p26 Kontrasti
p8	värisävy	p27 Entropia
p9	kyllästys	p28 Energia
p10	intensiteetti	p29 Homogeenisyys
p11	kontrasti	
p12	entropia	Kaltevuus
p13	energia	p30 Intensiteetti
p14	homogeenisyys	p31 Kontrasti
		p32 Entropia
Minimi L intensiteetti		p33 Energia
p15	värisävy	p34 Homogeenisyys
p16	kyllästys	
p17	intensiteetti	Pleokroismi
p18	kontrasti	p35 Pleokroismi
p19	entropia	
p20	energia	
p21	homogeenisyys	

Taulukko B2: Mineraalin tunnistamissovelluksilla saavutetut tulokset (Ross ym. [7] tekemän GO:a hyödyntävän sovelluksen tulokset esitetty sarakkeissa L1 ja L2, Thompson ym. [5] kehittämän KNV:ja hyödyntävän sovelluksen tulokset esitetty sarakkeessa NN). Taulukon numeroarvot ovat prosenttilukuja, P=paras, K=Keskiarvo. Muokattu Ross ym. tekemän taulukon pohjalta [7].

Mineraali		L1				L2				NN
		K=34		K=70		K=34		K=70		K=70
		Testi	Harj.	Testi	Harj.	Testi	Harj.	Testi	Harj.	Testi
Kvartsi	P	90.2	94.6	92.2	93.8	93.5	97.5	97.8	96.1	96.5
	K	84.7	90.9	85.7	88.9	88.3	93.7	90.1	92.5	
Kalimaa-sälpä	P	94.2	97.8	93.9	96.0	93.8	99.0	93.4	96.9	88.8
	K	89.7	95.9	91.0	93.5	90.7	97.8	90.8	93.9	
Plagio-klaasi	P	86.2	91.8	84.7	93.8	83.3	95.7	85.4	94.3	89.1
	K	75.9	88.0	78.9	88.9	78.6	91.8	80.2	91.0	
Biotiitti	P	98.1	98.1	-	-	96.6	99.4	-	-	97.3
	K	93.7	96.4	-	-	91.7	98.0	-	-	
Musko-viitti	P	98.3	96.6	-	-	97.6	99.9	-	-	-
	K	74.8	94.1	-	-	78.0	97.9	-	-	
Sarvi-välke	P	91.4	97.7	-	-	92.8	98.5	-	-	95.4
	K	86.8	94.7	-	-	86.1	95.8	-	-	
Klinopy-rokseeni	P	90.3	96.5	-	-	93.8	98.5	-	-	97.5
	K	81.0	88.1	-	-	84.9	92.8	-	-	
Oliiviini	P	90.0	94.4	89.9	93.8	91.4	96.6	93.2	98.1	92.8
	K	83.0	88.6	86.6	90.0	84.4	92.6	89.4	95.1	
Granaatti	P	98.2	99.7	98.9	99.6	97.8	100	99.4	99.8	97.4
	K	96.0	98.3	97.6	98.1	95.8	98.9	97.1	98.6	
Kalsiitti	P	92.1	97.4	91.8	95.2	92.8	99.0	95.1	98.2	96.0
	K	84.4	93.6	88.5	93.0	86.2	96.3	91.2	95.9	
Läpinäky-mättömät	P	97.7	99.9	97.7	99.9	98.3	100	98.1	100	95.2
	K	93.6	98.9	96.6	99.4	95.2	99.3	96.5	99.7	